

## LEGO 2 - 1ª LISTA DE EXERCÍCIOS

### PARTE 1 - CONCEITUAL

- 1) Utilizando as propriedades do somatório, mostre que a soma dos desvios de uma variável aleatória qualquer  $X$  com respeito à sua média  $\bar{X}$  é igual a zero.

Seja uma variável aleatória  $X = (X_1, X_2, \dots, X_n)$

QUEREMOS VERIFICAR:  $\sum_{i=1}^n (X_i - \bar{X}) \stackrel{?}{=} 0$

PELA DEFINIÇÃO DE MÉDIA, SABEMOS:  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \Rightarrow \sum_{i=1}^n X_i = n \cdot \bar{X}$  (1)

PELAS PROPRIEDADES DO SOMATÓRIO:

$$\sum_{i=1}^n (X_i - \bar{X}) = \sum_{i=1}^n X_i - \sum_{i=1}^n \bar{X} = \sum_{i=1}^n X_i - n \cdot \bar{X} = 0 //$$

Defina, no parâmetro de regressão linear, o conceito de erro e de resíduos.

- 2) Explique com suas palavras, em, no máximo, 2 ou 3 frases curtas, o que é:

- Processo Gerador de Dados (PGD)
- A diferença entre parâmetros e estatísticas
- A diferença entre erros e resíduos
- Pressuposto de Linearidade do modelo de regressão (ML.1)
- Pressuposto de que os indivíduos amostrados são independentes e identicamente distribuídos (iid), o segundo pressuposto do modelo de regressão (ML.2)
- Pressuposto de que não há colinearidade perfeita entre os regressores (ML.3)
- Pressuposto de exogeneidade e média condicional zero (ML.4)
- O conceito de homocedasticidade
- Pressuposto de Homocedasticidade (ML.5)

a) O PSD é o mecanismo que gera os dados do mundo real.

b) PARÂMETROS SÃO QUANTIDADES POPULACIONAIS, EM GERAL DESCONHECIDAS; ESTATÍSTICAS SÃO QUANTIDADES ESTIMADAS PARA OS PARÂMETROS, FREQUENTEMENTE A PARTIR DE AMOSTRAS

c) ERROS SÃO COMPONENTES ALEATÓRIOS <sup>↑ não observável!</sup> QUE FAZEM COM QUE PESSOAS IDÊNTICAS (i.e., COM AS MESMAS CARACTERÍSTICAS) APRESENTEM DIFERENÇAS NA VARIÁVEL DE INTERESSE. RESÍDUOS SÃO QUANTIDADES ESTIMADAS: VALOR OBSERVADO - ESTIMADO

d) PODEMOS ESTIMAR A VARIÁVEL DE INTERESSE  $Y$  A PARTIR DE UMA COMBINAÇÃO LINEAR DAS COLUNAS DE UMA MATRIZ  $X$ .

e) SUPosição DE AMOSTRAGEM ALEATÓRIA, OU SEJA, A INCLUSÃO DE UM INDIVÍDUO NA AMOSTRA NÃO TEM QUALQUER RELAÇÃO COM A INCLUSÃO DO OUTRO.

f) NENHUM REGRESSOR PODE SER UMA COMBINAÇÃO LINEAR EXATA DE UM OU MAIS REGRESSORES.

g) O ERRO SE DISTRIBUI DE FORMA ALEATÓRIA, DE FORMA INDEPENDENTE DOS REGRESSORES  $X$ .

h) OS ERROS POSSUEM A MESMA VARIÂNCIA PARA TODOS OS VALORES DAS VARIÁVEIS EXPLICATIVAS.

i)  $\text{Var}(u|x) = \sigma^2$ , i.e., O ERRO TEM A MESMA VARIÂNCIA DADO QUALQUER VALOR DA VARIÁVEL EXPLICATIVA.

- 3) Vamos tratar agora da importância da cláusula *ceteris paribus* e do pressuposto de exogeneidade (ML.4). Responda cada item em, no máximo, um parágrafo.
- O que significa a cláusula *ceteris paribus* e por que ela é importante?
  - Por que a satisfação da exogeneidade permite a interpretação dos coeficientes de regressão como efeitos causais?
  - Por que a regressão múltipla torna mais fácil satisfazer o pressuposto de exogeneidade?
  - O que acontece quando violamos o pressuposto de exogeneidade?

a) A CLÁUSULA *CETERIS PARIBUS* SIGNIFICA "TUDO MAIS CONSTATANTE", IMPORTANTE PORQUE QUEREMOS MEDIR O EFEITO ISOLADO DE UMA PARTICULAR COVARIÁVEL NA VARIÁVEL RESPOSTA - OU SEJA, SABER COM  $Y$  VARIA DADA UMA VARIAÇÃO EM  $X$ .

b) SATISFAZER A EXOGENEIDADE SIGNIFICA DIZER QUE ESTAMOS CONTROLANDO POR TODAS AS VARIÁVEIS QUE AFETAM  $Y$ , DE MODO QUE O ERRO SE DISTRIBUIRÁ ALEATORIAMENTE, DE FORMA INDEPENDENTE DOS REGRESSORES. NÃO HAVENDO OUTROS FATORES SISTEMÁTICOS AFETANDO  $Y$ , PODEMOS INTERPRETAR OS COEFICIENTES COMO EFEITOS CAUSAIS.

c) UMA ÚNICA VARIÁVEL, SOZINHA, DIFICILMENTE EXPLICARÁ TODA A VARIAÇÃO DE  $Y$ . AO CONTROLARMOS POR MAIS VARIÁVEIS, ESTAMOS MAIS PROXIMOS DE SATISFAZER A EXOGENEIDADE.

d) NOS CASOS EM QUE VIOLAMOS O PRESSUPOSTO DA EXOGENEIDADE (quase sempre), DEVEMOS INTERPRETAR OS COEFICIENTES DA REGRESSÃO NÃO COMO EFEITOS CAUSAIS, MAS COMO UM RESUMO DA CORRELAÇÃO ENTRE AS VARIÁVEIS.

- 4) Vamos tratar agora da correlação entre os regressores de uma regressão múltipla. Em todas as letras desse exercício, a resposta se relaciona com um mesmo problema de fundo: a noção de colinearidade perfeita, de Álgebra Linear. Responda sempre de forma breve, com no máximo 3 linhas.

- Por que não podemos inserir a mesma variável duas vezes como regressor em uma regressão múltipla?
- Suponha que você tenha uma variável explicativa com duas categorias (tal como sexo). Por que numa regressão múltipla que contém um intercepto/constante não podemos inserir, ao mesmo tempo, como regressores as duas dummies que podem ser geradas a partir dessa variável binária? Em outras palavras, por que devemos deixar uma das variáveis como "categoria de referência"?
- Se omitimos ou suprimimos a constante passa a ser possível inserir uma dummy indicadora do sexo feminino e, ao mesmo tempo, uma dummy indicadora de sexo masculino. Por que isso ocorre? Por que a omissão da constante torna desnecessária a existência de uma categoria de referência?

- 5) Derive o estimador da Regressão Linear Simples utilizando o Método dos Momentos (i.e. demonstre o passo a passo matemático, demonstre como se chega à fórmula). Não use vetores e matrizes (objetos típicos de Álgebra Linear) - use apenas da Álgebra que aprendemos no Ensino Médio e das Propriedades do Somatório. Faça todos os passos à mão e indique quando cada um dos pressupostos do Modelo Linear foi utilizado.

ASSUMA A DISPONIBILIDADE DE UMA AMOSTRA ALEATÓRIA  $\{(X_i, y_i) : i=1, \dots, n\}$ . A REGRESSÃO LINEAR SIMPLES PODE SER ESCRITA COMO:  $y_i = \beta_0 + \beta_1 x_i + u_i$  (1)

ASSIM COMO EM WOOLBRIDGE (2020), VAMOS DERIVAR OS ESTIMADORES  $\hat{\beta}_0$  E  $\hat{\beta}_1$  PARTINDO DO PRESSUPOSTO DA EXOGENEIDADE, ML.4:

$$E[u] = 0, \text{ E TAMBÉM } \text{COV}(x, u) = E[xu] = 0$$

PODEMOS REESCREVER (1) COMO  $u = y - \beta_0 - \beta_1 x$ , E ENTÃO TEMOS QUE

$$E[y - \beta_0 - \beta_1 x] = 0 \text{ (2) E } E[x(y - \beta_0 - \beta_1 x)] = 0 \text{ (3)}$$

AS EQUIVALÊNCIAS AMOSTRAIS DOS MOMENTOS (2) E (3) SÃO:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \text{ (4) E } \frac{1}{n} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \text{ (5)}$$

PODEMOS REESCREVER (4) PARA ENCONTRAR  $\hat{\beta}_0$ :

$$\frac{1}{n} \sum_{i=1}^n y_i - \frac{1}{n} \sum_{i=1}^n \hat{\beta}_0 - \frac{1}{n} \sum_{i=1}^n \hat{\beta}_1 x_i = 0 \Rightarrow \bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0 \Rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \text{ (6)}$$

AGORA BASTA SUBSTITUIR (6) EM (5) PARA ENCONTRAR  $\hat{\beta}_1$ :

$$\frac{1}{n} \sum_{i=1}^n x_i (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0 \Rightarrow \frac{1}{n} \sum_{i=1}^n x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i) = 0$$

$$\Rightarrow \frac{1}{n} \sum_{i=1}^n x_i (y_i - \bar{y}) + \frac{1}{n} \sum_{i=1}^n x_i (\hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i) = 0 \Rightarrow$$

$$\Rightarrow \frac{1}{n} \sum_{i=1}^n x_i (y_i - \bar{y}) = \hat{\beta}_1 \frac{1}{n} \sum_{i=1}^n x_i (x_i - \bar{x}) \Rightarrow \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})}$$

$$\text{OU AINDA } \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \text{ DO SOMATÓRIO}$$

$\sum_{i=1}^n x_i (x_i - \bar{x}) = \sum_{i=1}^n [(x_i - \bar{x}) + \bar{x}](x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})^2 + \bar{x} \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n (x_i - \bar{x})^2 + \bar{x} \cdot 0 = \sum_{i=1}^n (x_i - \bar{x})^2$  (ver exercício 1)

- 6) Derive o estimador da Regressão Linear Múltipla utilizando o Método dos Momentos (i.e. demonstre o passo a passo matemático, demonstre como se chega à fórmula). Use vetores e matrizes. Faça todos os passos à mão e indique quando cada um dos pressupostos do Modelo Linear foi utilizado.

POR ML.1, ESCRREVEMOS  $\vec{y} = X\vec{\beta} + \vec{e}$ . QUEREMOS ISOLAR  $\vec{\beta}$ .

POR ML.3, ASSUMIMOS QUE NÃO HÁ COLINEARIDADE PERFEITA E QUE  $X^T X$ , PORTANTO, É INVERTÍVEL.

$$\vec{y} = X\vec{\beta} + \vec{e} \Rightarrow X^T \vec{y} = X^T X \vec{\beta} + X^T \vec{e} \xrightarrow{\text{O, por ML.4 (exogeneidade)}}$$

$$\Rightarrow (X^T X)^{-1} X^T \vec{y} = (X^T X)^{-1} X^T X \vec{\beta} \Rightarrow \vec{\beta} = (X^T X)^{-1} X^T \vec{y}$$

\* como não estamos falando em variância, ainda não precisamos usar o pressuposto da homocedasticidade, ML.5.

- 7) Derive o estimador da Regressão Linear Simples utilizando o Método dos Mínimos Quadrados. Use Cálculo, derivadas e propriedades do somatório. Faça todos os passos à mão.

Em geral, queremos minimizar uma particular função de erro. No caso, em particular, queremos minimizar a distância quadrática entre o  $y$  verdadeiro ( $y_i$ ) e o  $y$  estimado ( $\hat{y}_i$ ).

Por ML.1:  $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + u_i$ ,  $i=1, \dots, n$ , numa amostra aleatória  $\{(x_i, y_i) : i=1, \dots, n\}$

Queremos minimizar a loss function  $\alpha(\hat{\beta}_0, \hat{\beta}_1)$ :

$$\alpha(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Dáí podemos extrair o seguinte sistema de equações:

$$\begin{cases} \frac{\partial f}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ \frac{\partial f}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \end{cases} \Rightarrow \text{ponto de mínimo erro com } \hat{\beta}_0 \text{ e } \hat{\beta}_1 \text{ (i.e., a derivada do erro com respeito aos dois parâmetros é zero)}$$

Note que chegamos precisamente às mesmas equações do exercício 5 e, portanto, chegamos precisamente aos mesmos estimadores para  $\hat{\beta}_1$  e  $\hat{\beta}_0$ . Dispensamos mais cálculos, portanto, já que eles foram realizados naquela oportunidade.

- 8) Os estimadores obtidos nos exercícios 5 e 7 são idênticos. Mas quais as diferenças conceituais entre o Método dos Momentos e o Método dos Mínimos quadrados? Responda em, no máximo, um parágrafo.

AS DIFERENÇAS CONCEITUAIS PRINCIPAIS ESTÃO NA MOTIVAÇÃO PARA ENCONTRAR  $\hat{\beta}$ : O MÉTODO DOS MOMENTOS ENCONTRA  $\hat{\beta}$  USANDO MOMENTOS POPULACIONAIS A MOMENTOS AMOSTRAIS; O MQO, POR OUTRO LADO, ENCONTRA  $\hat{\beta}$  MINIMIZANDO O ERRO QUADRÁTICO ENTRE O  $Y$  OBSERVADO E O  $Y$  ESTIMADO.