

Lego 2 – 1ª Lista de Exercícios

Parte 2: Prática

Felipe Lamarca

2025-10-05

Agora, passemos à parte prática da lista, na qual desenvolveremos algumas análises em R utilizando um banco de dados com informações a respeito dos municípios brasileiros em 1991, como a expectativa de vida ao nascer, população do município, Índice de Gini etc. De saída, vamos começar importando as bibliotecas necessárias, organizando um setup e lendo o arquivo que será utilizado na análise:

```
# importa as libs
library(tidyverse)
library(stargazer)

# remove o uso de e^
options(scipen = 999)

# leitura do arquivo
expectativaVida = read.csv("dados/dados_expectativaVida.csv")
```

O *output* do código abaixo é uma série de histogramas, uma para cada variável contínua do banco de dados sob análise:


```
# seleciona apenas as variáveis contínuas
dados_cont <- expectativaVida %>%
  select(esperanc, populaca, ginitrab, renda_me,
         escoa2_p, urbano_p, med1000, pop15a_f)

# transforma em formato longo pro facet
dados_long <- dados_cont %>%
  pivot_longer(cols = everything(),
               names_to = "variavel",
               values_to = "valor")

# plota todos os histogramas em facets
ggplot(dados_long, aes(x = valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  facet_wrap(~ variavel, scales = "free", ncol = 3) +
  labs(title = "Histogramas das variáveis contínuas",
```

```
x = NULL, y = NULL) +
theme_bw(base_size = 11)
```

Histogramas das variáveis contínuas



Há alguns pontos que valem destaque. Em particular, está claro que a grande parte dos municípios brasileiros possui população (**populaca**) bem pequenas; além disso, boa parte também possui um baixo percentual de domicílios com esgotamento sanitário (**esco2_p**). Vejamos na tabela abaixo algumas estatísticas descritivas para cada variável do banco:

```
# tabela com as estatísticas descritivas
desc = data.frame(
  variavel = names(expectativaVida),
  media = sapply(
    expectativaVida,
    function(x) if (is.numeric(x)) mean(x, na.rm = TRUE) else NA_real_
  ),
  mediana = sapply(
    expectativaVida,
    function(x) if (is.numeric(x)) median(x, na.rm = TRUE) else NA_real_
  ),
  desvio_padrao = sapply(
    expectativaVida,
    function(x) if (is.numeric(x)) sd(x, na.rm = TRUE) else NA_real_
  ),
  n_validos = sapply(
    expectativaVida,
```

```

function(x) sum(!is.na(x))
),
row.names = NULL
)

# numero de linhas
n = nrow(expectativaVida)

# proporcao de linhas validas (acho util, em particular)
desc$prop_validos = (desc$n_validos / n) * 100

# plot bonitinho da tabela
stargazer(
  desc,
  type = "text",
  summary = FALSE,
  title = "Estatísticas Descritivas",
  digits = 2,
  rownames = FALSE
)

```

Estatísticas Descritivas

```

=====
variavel   media   mediana desvio_padrao n_validos prop_validos
-----
esperanc   63.63    64.05    5.08         4,491      100
populaca  32,693.27 12,407   187,705.20   4,491      100
ginitrab   0.52     0.52     0.07         4,491      100
renda_me   274.29    238.57   164.68       4,491      100
escoa2_p   25.42     11.68    28.52        4,491      100
urbano_p   53.14     51.67    23.26        4,491      100
med1000    0.60     0.44     0.55         4,332      96.46
norte      0.07      0        0.25         4,491      100
centrooe   0.08      0        0.28         4,491      100
sul        0.19      0        0.40         4,491      100
nordeste   0.34      0        0.47         4,491      100
pop15a_f   15.14     14.08    7.96         4,491      100
-----

```

De fato, como já havíamos observado no histograma da variável `populaca`, os municípios têm, em geral, pequena população. Note, por exemplo, que 50% dos municípios possui população menor que 12.407 habitantes; há, no entanto, municípios com alta população, o que se reflete no desvio padrão. A esperança de vida ao nascer, nossa variável resposta para os exercícios subsequentes, tinha média 63.63 naquele ano. A coluna `prop_validos` também nos ajuda a compreender o percentual de observações daquela coluna que possuem valor *missing*.

Agora vamos rodar as regressões! Para ajustar alguns dos modelos a seguir, vamos implementar uma função de regressão linear *from scratch* em R. A função retorna os coeficientes da regressão (i.e. o vetor β), os erros-padrão desses coeficientes, seus p-valores, e algumas estatísticas próprias do modelo, como o R^2 , a variância dos resíduos e seu desvio-padrão (RMSE):

```
linear_model = function(formula, data = expectativaVida) {

  dependent_variable = as.character(formula[[2]])

  X = model.matrix(formula, data = data)
  y = data[[dependent_variable]]

  # beta estimado:  $\hat{\beta} = (X^T X)^{-1} X^T y$ 
  beta_hat = solve( t(X) %*% X ) %*% t(X) %*% y

  # y estimado a partir do modelo:  $\hat{y} = X \hat{\beta}$ 
  y_hat = X %*% beta_hat

  # residuals sao a diferenca entre y 'verdadeiro' e y estimado
  residuals = y - y_hat

  n = nrow(X)
  k = ncol(X)

  # erro quadratico medio
  var_residuals = sum(residuals^2) / (n - k)

  # raiz do erro quadratico medio
  RMSE = sqrt(var_residuals)

  # R-squared, ou proporcao da variancia explicada pelo modelo
  total_variance = var(y)
  R2 = 1 - var_residuals / total_variance

  # sob homocedasticidade (ML.5),  $\text{var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$ 
  # onde a equivalencia de  $\sigma^2$  para a amostra é a variância dos residuos
  varcov_beta_hat = var_residuals * solve( t(X) %*% X )
  se_beta_hat = sqrt(diag(varcov_beta_hat))

  # teste de hipotese para o p-valor
  H0 = 0 # teste contra a H0 de o efeito ser nulo
  t = (beta_hat - H0) / se_beta_hat
  p_valor = 2 * (1 - pnorm(abs(t)))

  coefs <- data.frame(
    Coeficientes = colnames(X),
    Estimativas = round(as.numeric(beta_hat), 4),
    Erros_padrao = round(se_beta_hat, 4),
```

```

    t = t,
    p_valor = p_valor,
    row.names = NULL,
    check.names = FALSE
  )

  list(
    coefs = coefs,
    R2 = R2,
    RMSE = RMSE,
    var_residuals = var_residuals
  )
}

```

A primeira regressão ajustada inclui apenas a variável de desigualdade de renda como variável explicativa (ginitrab) da esperança de vida ao nascer. Vejamos:

```
print(linear_model(formula = esperanc ~ ginitrab))
```

```

$coefs
  Coeficientes Estimativas Erros_padrao      t p_valor
1 (Intercept)    58.4775      0.5485 106.606577      0
2      ginitrab     9.9553      1.0509   9.473201      0

$R2
[1] 0.01938121

$RMSE
[1] 5.030641

$var_residuals
[1] 25.30735

```

Vale a pena testar se nossos resultados são idênticos aos obtidos quando usamos a função nativa do R para ajustar modelos lineares, `lm()`:

```

summary(
  lm(
    formula = esperanc ~ ginitrab,
    data = expectativaVida
  )
)

```

```

Call:
lm(formula = esperanc ~ ginitrab, data = expectativaVida)

```

Residuals:

	Min	1Q	Median	3Q	Max
	-13.9188	-3.8036	0.3425	3.9275	11.8394

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	58.4775	0.5485	106.607	<0.0000000000000002 ***
ginitrab	9.9553	1.0509	9.473	<0.0000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.031 on 4489 degrees of freedom

Multiple R-squared: 0.0196, Adjusted R-squared: 0.01938

F-statistic: 89.74 on 1 and 4489 DF, p-value: < 0.00000000000000022

São idênticos, felizmente! Podemos interpretar nossos resultados com tranquilidade.

O intercepto é o valor da variável dependente quando as variáveis independentes são zero. Nesse caso, portanto, dizemos que, quando `ginitrab` é zero – isto é, não há desigualdade de renda do trabalho –, a expectativa de vida ao nascer é 58.5, em média. β_1 , o coeficiente para `ginitrab`, indica que para o aumento em uma unidade de `ginitrab`, a expectativa de vida cresce em 9.95 anos. Esse resultado deveria ser estranho a qualquer cientista: estamos dizendo, em essência, que o aumento da desigualdade leva a um aumento na expectativa de vida. Trata-se, muito provavelmente, de um viés de variável omitida, mas voltaremos a essa questão oportunamente.

Os erros-padrão dos coeficientes são pequenos, o que nos leva a p-valores baixos, muito próximos de zero. Os efeitos, portanto, são estatisticamente significativos. O R-squared é baixo, então a variância explicada pelo modelo é pequena – ou seja, `ginitrab` sozinho explica pouco da variabilidade da variável resposta. Além disso, o erro médio das previsões é de 5 anos, conforme o valor do RMSE.

Agora, façamos uma pequena modificação na variável explicativa, multiplicando-a por 100.

```
expectativaVida = expectativaVida %>%
  mutate(
    ginitrab100 = ginitrab * 100
  )

reg1 = lm(formula = esperanc ~ ginitrab100, data = expectativaVida)

summary(reg1)
```

Call:

```
lm(formula = esperanc ~ ginitrab100, data = expectativaVida)
```

Residuals:

	Min	1Q	Median	3Q	Max
--	-----	----	--------	----	-----

-13.9188 -3.8036 0.3425 3.9275 11.8394

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	58.47755	0.54854	106.607	<0.0000000000000002 ***
ginitrab100	0.09955	0.01051	9.473	<0.0000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.031 on 4489 degrees of freedom

Multiple R-squared: 0.0196, Adjusted R-squared: 0.01938

F-statistic: 89.74 on 1 and 4489 DF, p-value: < 0.00000000000000022

A multiplicação não muda nada do ponto de vista estatístico, embora possa facilitar a interpretação dos resultados em certos casos. No caso em que não fizemos a multiplicação por 100, dizíamos que, aumentando `ginitrab` em uma unidade, aumentávamos a expectativa de vida em mais de 9 anos. Mas como `ginitrab` era uma variável contínua entre 0 e 1, estávamos indo de um cenário extremo para outro (de 0 para 1). Quando multiplicamos por 100, podemos dizer que o aumento em uma unidade do Índice de Gini leva a um incremento da expectativa de vida em 0.099 ano. Isso ainda não faz sentido do ponto de vista qualitativo, é claro, mas deixa a interpretação do coeficiente mais informativa.

Agora vamos lidar com o problema do viés de variável omitida. Em particular, vamos incluir a renda domiciliar per capita média como variável explicativa e analisar os coeficientes. Primeiro, vamos ajustar um modelo usando a função que criamos *from scratch*:

```
reg2_mine = linear_model(formula = esperanc ~ ginitrab100 + renda_me)
print(reg2_mine)
```

\$coefs

	Coeficientes	Estimativas	Erros_padrao	t	p_valor
1	(Intercept)	60.5965	0.4036	150.152844	0.000000000000000000
2	ginitrab100	-0.0574	0.0081	-7.081885	0.0000000000001421974
3	renda_me	0.0219	0.0004	62.168859	0.000000000000000000

\$R2

[1] 0.4730019

\$RMSE

[1] 3.687888

\$var_residuals

[1] 13.60052

Vamos checar se o resultado é o mesmo quando usamos `lm()`:

```
reg2 = lm(formula = esperanc ~ ginitrab100 + renda_me, data = expectativaVida)
summary(reg2)
```

Call:

```
lm(formula = esperanc ~ ginitrab100 + renda_me, data = expectativaVida)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-26.1536	-2.5072	0.1249	2.6296	10.0669

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	60.5965070	0.4035655	150.153	< 0.00000000000000002 ***
ginitrab100	-0.0574135	0.0081071	-7.082	0.000000000000164 ***
renda_me	0.0218646	0.0003517	62.169	< 0.00000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.688 on 4488 degrees of freedom

Multiple R-squared: 0.4732, Adjusted R-squared: 0.473

F-statistic: 2016 on 2 and 4488 DF, p-value: < 0.000000000000000022

Tudo certo! Vejamos os resultados, então. Agora, finalmente, temos um coeficiente para `ginitrab100` que faz mais sentido (dessa vez, negativo). Quando aumentamos o Índice de Gini em uma unidade e mantemos o resto fixo, a expectativa de vida ao nascer decresce, em média, em 0.05 ano. Além disso, para uma unidade que incrementamos na renda per capita média do município – mantendo o resto fixo –, a expectativa de vida ao nascer cresce em 0.02 ano. Todos os coeficientes são estatisticamente significativos e possuem baixo erro-padrão. Além disso, o R-squared é substantivamente melhor do que o observado no primeiro modelo.

A interpretação do coeficiente para `ginitrab100` é diferente porque, antes, não controlávamos por outras variáveis que afetavam tanto a expectativa de vida quanto `ginitrab100`, como a renda per capita média. Nesse caso, havia pelo menos uma variável confundidora, `renda_me`, que enviesava a estimativa do beta para `ginitrab100`.

Vamos incluir mais variáveis no modelo para verificar como os resultados se comportam. Dessa vez, vamos incluir `log(populaca)`:

```
reg3 = lm(
  formula = esperanc ~ ginitrab100 + renda_me + log(populaca),
  data = expectativaVida
)

summary(reg3)
```



```

Call:
lm(formula = esperanc ~ ginitrab100 + renda_me + log(populaca),
    data = expectativaVida)

Residuals:
    Min       1Q   Median       3Q      Max
-29.5079  -2.2982   0.1263   2.5502  10.2874

Coefficients:
              Estimate Std. Error t value      Pr(>|t|)
(Intercept)  68.9810535   0.5866102  117.593 < 0.00000000000000002 ***
ginitrab100  -0.0447944   0.0078263   -5.724   0.0000000111 ***
renda_me      0.0235496   0.0003497   67.351 < 0.00000000000000002 ***
log(populaca) -0.9984062   0.0523691  -19.065 < 0.00000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.547 on 4487 degrees of freedom
Multiple R-squared:  0.5127,    Adjusted R-squared:  0.5124
F-statistic: 1574 on 3 and 4487 DF,  p-value: < 0.000000000000000022

```

Ao incluir $\log(\text{populaca})$, as estimativas dos betas para `ginitrab100` e `renda_me` não se alteraram grosseiramente. Os coeficientes são todos estatisticamente significativos, e tivemos um ganho não-ignorável no R-squared. Ao incluir a variável da população na escala logarítmica, estamos comprimindo a escala dessa variável para evitar que o modelo seja muito sensível à alta variância dessa covariável. Vimos entre as estatísticas descritivas, por exemplo, que o desvio-padrão da população dos municípios é altíssima.

Para interpretar o coeficiente de $\log(\text{populaca})$, precisamos levar em consideração algumas propriedades do logaritmo. Em particular, devemos usar a seguinte aproximação, conforme demonstrado em...

$$\log(X_{\text{final}}) - \log(X_{\text{inicial}}) = \log\left(\frac{X_{\text{final}}}{X_{\text{inicial}}}\right) \approx \log\left(\frac{X_{\text{final}} - X_{\text{inicial}}}{X_{\text{inicial}}}\right) = \log\left(\frac{\Delta X}{X_{\text{inicial}}}\right),$$

presumindo que ΔX é suficientemente pequeno. Dito de outro modo, podemos interpretar o coeficiente da variável na escala log em termos de variação percentual. Portanto, a cada uma unidade de $\log(\text{populaca})$ que aumentamos a população em 1%, controlando pelas demais variáveis, diminuimos a expectativa de vida ao nascer em aproximadamente 0.0099 ano, em média.

Por fim, vamos ajustar um modelo com todas as covariáveis disponíveis:

```

formula_ = esperanc ~ ginitrab100 + renda_me + log(populaca) + escoa2_p +
  urbano_p + med1000 + pop15a_f + norte + centrooe + sul + nordeste

reg4 = lm(
  formula = formula_,
  data = expectativaVida
)

summary(reg4)

```

```

Call:
lm(formula = formula_, data = expectativaVida)

Residuals:
    Min       1Q   Median       3Q      Max
-9.1851 -1.9687  0.1669  2.1229  9.1558

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  67.6369495   0.5171727 130.782 < 0.00000000000000002 ***
ginitrab100  -0.0294642   0.0067134  -4.389  0.00001166656782484 ***
renda_me      0.0081743   0.0005242  15.595 < 0.00000000000000002 ***
log(populaca) -0.4789586   0.0505342  -9.478 < 0.00000000000000002 ***
escoa2_p      0.0212725   0.0025488   8.346 < 0.00000000000000002 ***
urbano_p     -0.0239271   0.0029920  -7.997  0.000000000000000162 ***
med1000      -0.1784613   0.0947582  -1.883    0.0597 .
pop15a_f      0.1467231   0.0115450  12.709 < 0.00000000000000002 ***
norte        -2.1534272   0.2196830  -9.802 < 0.00000000000000002 ***
centrooe     -1.2653372   0.1969555  -6.424  0.00000000014662483 ***
sul           1.1204752   0.1410866   7.942  0.000000000000000252 ***
nordeste     -4.5303204   0.1503863 -30.125 < 0.00000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.879 on 4320 degrees of freedom
(159 observations deleted due to missingness)
Multiple R-squared:  0.6785,    Adjusted R-squared:  0.6777
F-statistic: 829 on 11 and 4320 DF, p-value: < 0.00000000000000022

```

Os ganhos são claros: temos um R-squared de 0.68, e praticamente todos os coeficientes são estatisticamente significativos, com exceção de `med1000`. O coeficiente da renda per capita média do município perdeu magnitude, um resultado provavelmente resultante da correlação entre essa variável e as demais variáveis do modelo. Quando as demais variáveis não eram incluídas, `renda_me` assumia parte desses efeitos. Algo semelhante ocorreu, inclusive, com a variável `log(populaca)`.

Observe também as variáveis categóricas do modelo. Note, em particular, que não foi incluída a variável `sudeste`, que de fato sequer existia no banco de dados. Como discutimos na parte conceitual desta lista, a inclusão da variável `sudeste` introduziria colinearidade perfeita no modelo e impediria o cálculo dos coeficientes. A consequência, aqui, é que Sudeste é a categoria de base. Do ponto de vista interpretativo, observamos que o fato de o município fazer parte da região Sul está, em média, associado a maiores expectativas de vida ao nascer do que no Sudeste; observamos o contrário, no entanto, para as regiões Centro-Oeste, Norte e sobretudo Nordeste.

A tabela abaixo sistematiza os resultados de todos os modelos ajustados em uma única tabela para facilitar a visualização dos resultados. Outra alternativa seria apresentar os coeficientes graficamente.

```
stargazer(reg1, reg2, reg3, reg4,
          type = "text",
          title = "Modelos de Regressão Linear ajustados",
          dep.var.labels = "Esperança de Vida",
          column.labels = c("Modelo 1", "Modelo 2", "Modelo 3", "Modelo 4"),
          digits = 3,
          omit.stat = c("f", "adj.rsq", "ll", "aic"))
```

Modelos de Regressão Linear ajustados

Dependent variable:				
	Esperança de Vida			
	Modelo 1	Modelo 2	Modelo 3	Modelo 4
	(1)	(2)	(3)	(4)
ginitrab100	0.100*** (0.011)	-0.057*** (0.008)	-0.045*** (0.008)	-0.029*** (0.007)
renda_me		0.022*** (0.0004)	0.024*** (0.0003)	0.008*** (0.001)
log(populaca)			-0.998*** (0.052)	-0.479*** (0.051)
escoa2_p				0.021*** (0.003)
urbano_p				-0.024*** (0.003)
med1000				-0.178* (0.095)
pop15a_f				0.147*** (0.012)
norte				-2.153*** (0.220)
centrooe				-1.265*** (0.197)
sul				1.120*** (0.141)

nordeste				-4.530*** (0.150)
Constant	58.478*** (0.549)	60.597*** (0.404)	68.981*** (0.587)	67.637*** (0.517)

Observations	4,491	4,491	4,491	4,332
R2	0.020	0.473	0.513	0.679
Residual Std. Error	5.031 (df = 4489)	3.688 (df = 4488)	3.547 (df = 4487)	2.879 (df = 4320)
=====				
Note:	*p<0.1; **p<0.05; ***p<0.01			

Por fim, um último comentário: embora o modelo 4 inclua uma série de covariáveis importantes que nos ajudam a compreender o comportamento da expectativa de vida, ele ainda não tem interpretação causal. De fato, estamos controlando por uma série de variáveis, mas não por todas; certamente há outros fatores que afetam não apenas a variável de interesse, como também as variáveis independentes – isso inclui, por exemplo, questões associadas à política local, repasses financeiros do governo federal e governos estaduais para os municípios, fatores conjunturais e assim por diante. Isso não altera o fato, no entanto, de que o modelo 4 está mais próximo de oferecer uma explicação causal do que o modelo 1.